



덕트 공동 탐지를 위한 LSTM Auto-Encoder

LSTM Auto-Encoder for Duct Void Detection

저자 (Authors)	이다인, 오병두, 최형, 김유섭 Da-In Lee, Byoung-Doo Oh, Hyung Choi, Yu-Seop Kim
출처 (Source)	한국정보과학회 학술발표논문집 , 2021.6, 531-533 (3 pages)
발행처 (Publisher)	한국정보과학회 The Korean Institute of Information Scientists and Engineers
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE10582990
APA Style	이다인, 오병두, 최형, 김유섭 (2021). 덕트 공동 탐지를 위한 LSTM Auto-Encoder. 한국정보과학회 학술발표논문집, 531-533.
이용정보 (Accessed)	한림대학교 210.115.***.234 2021/08/17 13:57 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

덕트 공동 탐지를 위한 LSTM Auto-Encoder*

이다인^{1,0}, 오병두¹, 최형², 김유섭¹¹한림대학교 융합소프트웨어학과²AI bridge Co., Ltd{daine96⁰, Iambd822, henrychoi9}@gmail.com, yskim01@hallym.ac.kr

LSTM Auto-Encoder for Duct Void Detection


Da-In Lee^{1,0}, Byoung-Doo Oh¹, Hyung Choi², Yu-Seop Kim¹¹Convergence Software, Hallym University²AI bridge Co., Ltd

요 약

PSC 박스 거더교는 박스 형태의 거더에 미리 응력을 가한 교량으로 가장 많이 이용되는 방식이다. 그러나 콘크리트를 타설 할 때, 덕트의 내부 직경이 작기 때문에 작은 실수로도 공동이 발생할 수 있다. 또한 거더교의 장기간 유지 시에는 결함이 나타날 수 있다. 이러한 결함을 감지하기 위해 비파괴 검사인 Impact-Echo (IE) 방식으로 데이터를 수집한다. 본 연구에서는 PSC 박스 거더교 내부 덕트의 정상과 공동 여부를 탐지하기 위한 방법을 제시한다. 이는 비지도 학습인 Auto-Encoder (AE)를 바탕으로 시계열 데이터 처리에 좋은 LSTM을 적용한다. 정상 IE 신호로 LSTM AE를 훈련시킨 후, 각 평가 데이터로 AE 모델의 Encoder에서 나온 Latent Vector를 통해 데이터의 분포를 비교 분석한다. 이때 사전 학습된 LSTM AE는 정상 데이터로 학습되었기 때문에, Encoder에 공동 데이터를 넣어서 나온 Latent Vector는 정상 데이터 Latent Vector와 낮은 유사도를 갖는다. 그러므로 구해진 평균 유사도를 통해 모델의 성능을 평가할 수 있고, PSC 박스 거더교 내부에 있는 덕트의 정상과 공동 여부를 예측 가능하다.

1. 서 론

콘크리트는 본래 압축응력은 강하지만 휨응력에는 약하다. 이러한 단점을 보완하기 위해 발명된 PSC (Pre-stressed Concrete)는 미리 응력을 준 콘크리트이다. 현재까지 건설된 고속철도교의 경우 PSC 박스 거더교가 90% 이상을 차지하여 가장 많이 사용되는 교량 형식이다. 그렇기 때문에 PSC 박스 거더교를 설계할 경우 국가 SOC사업 비용을 절감하는 효과를 도출할 수 있다 [1]. [그림1]과 같이 콘크리트 속에 강연선을 넣고 강력하게 잡아당겨 고정시키면, 내부에 압축응력이 작용하게 된다. 이때, 강연선은 부식을 막기 위해 덕트 안에 삽입된 상태여야 하며 강연선의 인장력을 통해 상향력이 발생하고 휨응력이 강한 콘크리트가 만들어진다.



[그림1] PSC (Prestressed Concrete) 개요도

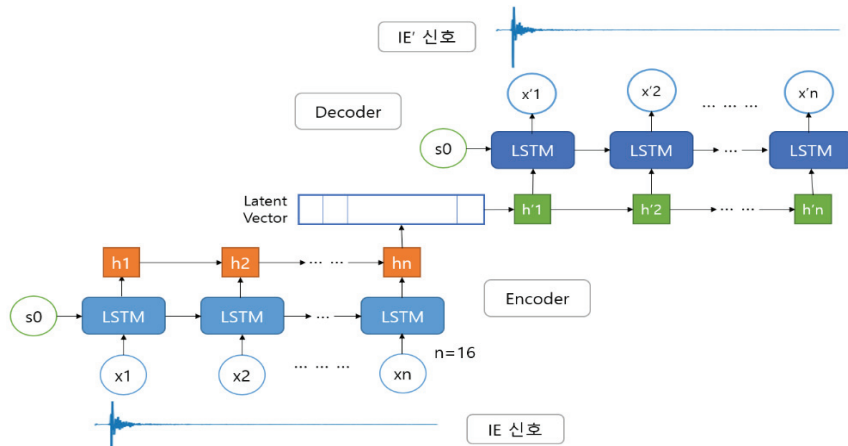
그러나 현장에서 콘크리트를 직접 타설 할 때, 덕트의 내부 직경이 아주 작기 때문에 시공의 정밀도가 낮아질 수 있다. 또한, 거더교의 장기간 유지 시에는 덕트 내부의 공동이 나타

날 수 있다. 이를 방지하기 위해 PSC 박스 거더교의 안정성을 확인하는 내부 덕트 탐사 작업은 매우 중요하다. 콘크리트에서의 결함을 감지하는 기술은 비파괴 검사인 Impact-Echo (IE) 방식을 많이 활용한다. 이 방법은 단기간의 기계적 충격으로 인한 진동을 통해 대상의 결함 여부를 탐지한다. 그러나 전문가의 학문적인 지식을 기반으로 신호를 해석하더라도, 규칙을 발견하기 어려워 정확한 판단에 한계가 있다.

그러므로 본 연구에서는 PSC 박스 거더교 덕트 내부의 정상과 공동 여부를 탐지하기 위한 딥러닝 방식을 제시한다. IE를 측정하는 환경에 따라 신호의 패턴이 달라지기 때문에, 비지도 학습의 일종인 Auto-Encoder (AE)를 바탕으로 한다. 일반적으로 정상보다 공동이 발생할 확률이 매우 적으며, AE를 통해 학습한 신호들의 유의미한 차이를 통해 구분이 가능할 것이다. 그리고 시계열 데이터를 처리하는 데에 성능이 좋은 Long Short-Term Memory (LSTM)을 응용한다.

먼저, 정의된 LSTM AE를 정상 IE 신호 데이터로 학습한다. 그리고 나서 각 평가 데이터로 AE 모델 테스트시, Encoder에서 나온 Latent Vector를 통해 데이터의 분포를 비교 분석하고자 한다. 사전 학습된 AE 모델에 정상 평가 데이터를 넣었을 때의 Latent Vector의 평균 유사도를 구하고, 추가적으로 공동 평가 데이터를 Encoder에 넣은 Latent vector간의 평균 유사도를 구한다.

*본 연구는 2020년도 중소벤처기업부의 기술개발사업 지원에 의한 연구임 (G21S297332301).




[그림 3] Filtering된 IE 신호와 LSTM AE 모델 구조

그 결과, 공동 데이터와 같이 평가하였을 때의 유사도는 정상 데이터만 평가하였을 때보다 더 낮은 유사도가 출력된다. 결론적으로 사전 학습된 LSTM AE는 정상 데이터로 학습되었기 때문에, Encoder에 공동 데이터를 넣어서 나온 Latent Vector와 정상 데이터 Latent Vector의 유사도가 낮게 나온다. 그러므로 구해진 평균 유사도를 통해 모델의 성능을 평가하는 것이 가능하고, 이 방법을 통해 PSC 박스 거더교 덩트 내부의 정상과 공동 여부를 예측할 수 있다.

2. 데이터

2.1 PSC 시험체

본 연구에서는 실제 PSC 박스 거더교와 동일한 구조의 시험체를 제작하였다. 덩트 결함의 위치 및 형태에 따라 7가지 시험체로 구성되며 [그림 2]과 같다. 결함의 형태는 정사각형과 사다리꼴로 제작하였다.



[그림 2] 제작된 7가지의 PSC 시험체

2.2 Impact-Echo 신호

시험체의 덩트 내부 결함을 감지하는 기술은 비파괴 검사인 Impact-Echo (IE) 신호를 활용한다. 이 방법은 단기간의 기계적 충격으로 인한 표면 움직임을 기반으로 신호 데이터가 생성된다. 각각 다른 진동을 일으키기 때문에 탐지 대상의 형상 및 결함의 존재와 관련이 있다 [2]. 본 연구에서는 0 ~ 1024μs 길이의 신호를 사용하였고, 처리를 위해 원시 신호를 각각 Low-pass, High-pass로 필터링하였다.

3. 방법론

본 연구에서 구성한 모델의 구조는 [그림3]과 같으며, LSTM AE를 활용한 PSC 박스 거더교의 덩트 공동 탐지 방식을 제시한다. 정상 IE 신호는 시계열 데이터 이므로


순차적으로 LSTM AE에 입력한다. 각 LSTM에서 나온 Hidden Vector를 통해 Latent Vector가 생성되고, Encoder와 반대로 Decoder는 같은 방법으로 IE 신호를 복원하는 과정이다. 수행 과정은 정상 훈련 IE 신호 데이터로 훈련을 마치고 나서, LSTM AE에 훈련되지 않은 IE 신호 데이터로 평가한다. 이때, Encoder에서 나온 Latent Vector를 통해 훈련이 잘 되었는지 모델의 성능을 분석하고자 한다.

3.1 LSTM Auto-Encoder

AE는 입력, 은닉, 출력 계층의 순차적으로 연결된 3계층 배열로 구성된 인공 신경망이며, 비지도 학습 방식이다. 훈련 절차는 입력 데이터가 은닉 계층에 매핑 되는 Encoder와 입력 데이터가 다시 복원되는 Decoder로 구성된다. 입력 데이터와 재구성된 출력 데이터의 차이를 일반적으로 재구성 오류라고 하며, 이 오류를 줄이기 위해 학습하는 모델이다.

feed-forward 신경망 기반의 기존 AE에서 순환 네트워크인 LSTM 기반 AE로 변경하여 적용한다. IE 신호는 시계열 데이터이므로 LSTM은 순차적인 데이터 처리에 성능이 좋아 적합하다. LSTM AE는 2개의 LSTM 계층으로 구성된다. Encoder는 입력 시퀀스(x_1, x_2, \dots, x_n)를 Latent Vector로 인코딩하고 Decoder는 해당 벡터를 입력으로 사용하여 입력 시퀀스를 재구성(x'_1, x'_2, \dots, x'_n)한다 [3].

3.2 Latent Vector



[그림4] Pretrained LSTM Encoder의 Latent Vector 생성

정상 데이터로 사전 훈련된 LSTM AE를 통해 이상탐지가 가능하다 [4]. Latent Vector는 Encoder에서 나온 해당 입력 데이터에 대한 함축적인 표현이며, 시각적으로 표현하면

[그림4]와 같다. 본 연구에서는 각 정상 IE 신호와 비정상 IE 신호의 Latent Vector 유사도를 통해 이상을 탐지한다. 즉, 덕트의 결함을 탐지하기 위해 LSTM AE를 정상 신호로만 사전 훈련하고, 훈련된 Encoder에서 나온 정상 및 공동 신호의 Latent Vector들의 유사도를 비교 분석한다.


3.3 Cosine Similarity

정상과 공동 신호를 입력으로 LSTM AE의 Latent Vector 유사도를 분석할 때, 벡터 간의 거리를 비교하는 Euclidean 거리로 유사도를 측정할 수 있다. 그러나 본 연구에서는 이를 대체하는 두 벡터 간의 cosine 각도를 이용한 Cosine Similarity 방식을 사용한다 [5]. 이는 수식 (1)과 같이 정의되며, A와 B는 비교하고자 하는 각 Vector를 의미한다. [-1,1]에 해당하는 수로 1에 가까울 수록 유사도가 높은 것이다.

$$similarity = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}} \quad (1)$$

4. 실험 결과

본 연구에서 LSTM AE를 평가하는 과정의 입력 IE 신호와 출력 IE 신호 데이터의 출력은 [그림5]와 같다. 다음과 같이 Filtering된 IE 신호 데이터는 AE를 거쳐 복원된다. 완전하게 동일하지 않지만 비슷한 시계열의 양상을 보인다.



[그림 5] AE의 입력 및 출력 IE 신호

PSC 시험체의 콘크리트 두께는 25~28, 45, 60, 70, 90, 100, 115cm 7가지로 구분된다. 이처럼, 분류된 각 두께 시험체에서 측정된 IE 신호에 따라 AE 모델을 훈련 및 평가한다. 정상 IE 신호 데이터로 훈련된 LSTM AE 모델에 정상 평가 IE 신호를 Encoder에 입력한다. 이때, Encoder에서 나온 Latent Vector의 평균 Cosine Similarity는 모두 0.90이상으로 유사하게 나타난다. 그러나, 결함이 있는 공동 IE 신호와 정상 IE 신호의 Cosine Similarity의 평균을 측정하면 이전에 측정된 값보다 더 낮은 유사도가 나온다. 이에 대한 결과의 자세한 수치는 [표1]과 같다.

평균 유사도의 차이가 두드러지게 나타나지 않은 결과의 PSC 두께는 25~28, 60, 100, 115cm이며, 0.0047부터 0.03 이하의 미세한 차이를 보인다. 그러나 45, 70, 90cm의 두께를 가진 시험체의 평균 Cosine Similarity 결과는 더 큰 차이를 보인다. 먼저, 45cm 시험체의 경우 0.9044에서 0.8493으로 0.0551의 차이를 보이며, 60cm 시험체는 0.9421에서 0.8787로 0.0634만큼 낮아진다. 마지막으로 90cm 시험체는 0.9052에서 0.8619로 0.0433만큼 평균 Cosine Similarity가 낮아진다. 실험 결과를 통해, 정상 데이터로 훈련된 LSTM AE의 Encoder에서 나온 Latent vector는 입력 데이터에 대한 함축적인 표현이며, 공동 탐지에 도움이 됨을 알 수 있다.

[표 1] 시험체 두께에 따른 Cosine Similarity 평균

두께 Data	25~28 cm	45 cm	60 cm	70 cm	90 cm	100 cm	115 cm
AE훈련 (정상)	1023	319	5488	239	1024	1023	319
AE평가 (정상)	256	80	1373	60	40	256	80
Cosine similarity 평균	0.9412	0.90 44	0.97 75	0.94 21	0.90 52	0.92 76	0.90 94
AE평가 (정상)	256	80	1373	60	40	256	80
AE평가 (공동)	1159	400	1585	400	399	1159	400
Cosine similarity 평균	0.9164	0.84 93	0.97 28	0.87 87	0.86 19	0.92 2	0.90 46

5. 결 론

본 연구는 LSTM Auto-Encoder의 성질을 이용한 Latent Vector를 통해 평균 Cosine Similarity로 데이터를 비교 분석한다. 모델의 훈련 데이터는 정상 IE신호로만 이루어지며, 정상 IE신호를 평가한 결과와 결함이 있는 공동 IE신호를 포함하여 평가한 결과를 비교한다. 모두 어느 정도의 차이로 평균 Cosine Similarity가 낮아지며, 눈에 띄는 유사도 차이를 보이는 두께는 7가지의 PSC 시험체 중 45, 70, 90cm이다. 결론적으로, 정상 데이터로 훈련된 AE에 비정상 데이터가 입력되면 정상 Latent Vector와의 차이가 나타남을 알 수 있고 이를 통한 PSC 덕트 공동 탐지가 가능하다.

참 고 문 헌

- [1] 조경식, et al. "PSC 박스 거더 철도교량 최적단면." *한국철도학회 학술발표대회논문집*: 172-176. 2015.
- [2] Carino, Nicholas J. "The impact-echo method: an overview." *Structures 2001: A Structural Engineering Odyssey*: 1-18. 2001.
- [3] Sagheer, Alaa, and Mostafa Kotb. "Unsupervised pre-training of a deep LSTM-based stacked autoencoder for multivariate time series forecasting problems." *Scientific reports* 9.1: 1-16. 2019.
- [4] GHRIB, Zeineb; JAZIRI, Rakia; ROMDHANE, Rim. Hybrid approach for anomaly detection in time series data. In: *2020 International Joint Conference on Neural Networks (IJCNN)*. IEEE, p. 1-7. 2020.
- [5] MUFLIKHAH, Laili; BAHARUDIN, Baharum. Document clustering using concept space and cosine similarity measurement. In: *2009 International Conference on Computer Technology and Development*. IEEE, p. 58-62. 2009.